




南开大学
Nankai University

面向单细胞数据的 ANN 检索系统

软件工程第 13 组



汇报 提纲

CONTENTS

- 01 | 项目背景与系统架构
- 02 | 核心功能实现
- 03 | RAG 检索与用户权限管理
- 04 | 总结与后续计划

项目背景

- 单细胞测序产生**数十万个细胞样本**，每个细胞是一个**高维向量**
- 传统精确搜索在大规模高维数据上**效率极低**
- ANN (Approximate Nearest Neighbor) 技术在**质量与速度之间取得平衡**

系统目标

- 全栈 Web 应用：数据上传 → 预处理 → 索引 → 检索 → 可视化
- 至少实现一种 ANN 算法，支持 Top-K 相似细胞搜索
- 返回完整细胞信息：名称、元数据、距离值、查询耗时




图 1: 系统整体架构图

技术栈

层级 技术

前端	React 18 + MUI 5 + Recharts
后端	Flask 2.3 + JWT
ANN	FAISS / Annoy / ChromaDB
存储	MySQL + 本地文件系统

Dashboard 仪表盘说明

- 右侧为系统主界面，提供**数据管理**与**索引管理**两个核心入口
- 概览卡片实时显示数据集数量、索引数量及最近搜索活动
- 导航栏支持中英文切换、深色/浅色主题切换




图 2: Dashboard 主页

汇报 提纲

CONTENTS

项目背景与系统架构

核心功能实现

RAG 检索与用户权限管理

总结与后续计划

支持的数据格式

- **CSV / TSV**: 通用表格格式
- **HDF5 (.h5)**: 通用层级数据格式
- **H5AD (.h5ad)**: AnnData 格式, 单细胞数据标准

课程数据适配

- 优先读取 `obsm["X_pca"]` 作为检索向量
- `obs` 元数据作为细胞标签 (`cell_type`、`disease` 等)
- 支持 UMAP / t-SNE 坐标用于可视化

✓ 课程要求 1/6

单细胞数据读取




图 3: 数据管理界面全貌

数据向量化表示

向量化流程

- 每个细胞 → 一个高维向量 (PCA 降维后 50–100 维)
- 课程数据: 直接使用 `obsm["X_pca"]` 预计算 PCA 嵌入
- Demo 数据: 随机生成可调维度的高斯分布向量
- 数据上传后自动解析, 提取细胞名、特征名、元数据

✓ 课程要求 2/6

数据向量化表示



图 4: 数据向量化结果

两种预处理方式

- **L2 归一化** (按细胞): 每行缩放至单位范数
- **标准化** (按特征): 每列 z-score 标准化

预处理特性

- 原始数据保留在 data_web, 预处理副本写入 data_pre
- 预处理后自动切换存储位置, 检索与索引构建使用处理后的数据
- 数据集状态标签实时更新 (如 “preprocessed (L2 normalized)”)

数据管理界面




图 5: 数据预处理

构建流程

- 选择已上传的数据集
- 选择索引类型：FAISS Flat、FAISS IVF、Annoy
- 选择距离度量：L2 / Cosine / Inner Product
- 一键构建，自动保存到磁盘

索引管理

- 索引列表展示：类型、度量、细胞数、特征数、构建耗时
- 支持查看详情、删除索引
- 索引文件保存在
backend/storage/indices/

索引构建界面

构建 ANN 索引

数据集

索引类型

距离度量

FAISS Flat

L2 (Euclidean)

 构建索引

可用索引

类型	距离度量	细胞数	特征数	构建耗时 (秒)	操作
FAISS IVF	COSINE	69,032	30	0.199	
FAISS Flat	L2	69,032	30	0.028	

图 6: 索引构建界面

✓ 课程要求 3/6

ANN 索引构建

联合索引 (Joint Index)

- 基于 **ChromaDB HNSW**，支持多数据集合并为单一索引
- 跨数据集检索：一次查询，覆盖多个数据集
- 构建时自动将各数据集向量写入 ChromaDB Collection

功能

- 独立管理界面：构建表单、索引列表、删除
- 支持自然语言查询（配合 RAG 模块）
- 查询返回跨数据集 Top-K 结果

联合索引 (多数据集)

构建联合索引

联合索引在后台使用 ChromaDB 的 HNSW 实现，索引类型由系统管理，无需用户选择。



可用联合索引

索引名称	类型	度量方式	数据集数	总数据数	构建耗时 (秒)	操作
------	----	------	------	------	----------	----

当前还没有联合索引，请先在上方构建。

图 7: 联合索引管理界面

三种检索方式

- **向量检索**：直接输入数值向量
- **按细胞 ID 检索**：以数据集中某细胞为查询
- **自然语言检索**：RAG 驱动的 AI 智能搜索

检索参数

- 选择已构建的 ANN 索引
- 设置 Top-K (1-1000)
- 可选元数据过滤条件
(cell_type、disease、AgeGroup、donor_id)

✓ 课程要求 4/6

相似细胞检索




图 8: 搜索面板

实现的 ANN 算法与检索库

系统实现了 3 种 ANN 索引类型 + 1 种联合索引引擎，覆盖主流方案：

FAISS Flat (Facebook AI Similarity Search)

- 暴力搜索，遍历全部向量，返回**精确 Top-K**
- 适合小规模数据集 (<10 万细胞)，100% 召回率
- 底层 C++ 实现，单机 CPU 即可运行

ChromaDB HNSW (联合索引引擎)

- 分层可导航小世界图 (HNSW)，搜索复杂度 $O(\log N)$
- 多数据集合并为一个 Collection，支持跨数据集检索
- 配合 RAG 模块实现自然语言语义搜索

Annoy (Approximate Nearest Neighbors Oh Yeah)

- 基于随机投影树，递归划分向量空间
- `n_trees` 控制索引精度（树越多越精确，构建越慢）
- 内存映射加载，无需全部读入内存

FAISS IVF (Inverted File Index)

- 倒排索引：先用 KMeans 聚类划分空间，搜索时仅扫描邻近聚类
- `nlist` 参数自动计算 ($\sqrt{N}$)，平衡速度与精度
- 适合中等至大规模数据集

✓ 课程要求 5/6

至少实现一种 ANN 算法或检索库——已实现 3 种 ANN 索引 + ChromaDB HNSW 联合索引

Top-K 检索

- 返回 **Top-K** 个最相似细胞 (K 值 1–1000 可调)
- 每条结果包含：**排序序号、细胞名称、距离值、全部元数据**
- 显示**查询耗时** (ms)，直观反映索引性能
- 支持 **CSV 一键导出**检索结果

结果可视化

- Recharts **距离分布柱状图**：直观对比各候选细胞距离
- 当前活跃的**过滤条件标签**：实时显示 cell_type、disease 等筛选条件




图 9: 检索结果展示

搜索历史管理

- 自动保存最近 **10 条** 搜索记录
- 记录类型：向量检索、按细胞 ID 检索、RAG 检索
- 支持**单条删除**、**批量删除**、**一键清空**
- 清空需要输入确认原因，防止误操作

CSV 数据导出

- 检索结果一键导出为 CSV 文件
- 包含排名、细胞 ID、细胞名称、距离值等全部字段
- 支持中英文列名（根据界面语言自动切换）

✓ 课程要求 6/6

支持 Top-K 相似细胞搜索，并返回对应细胞信息

完整检索链路

选择索引 → 输入向量/细胞 ID → 设置 K 值/过滤条件 → 发起检索 →
返回 Top-K 结果 → 图表可视化 → CSV 导出 → 记录历史

三种距离度量方式

(系统支持三种距离度量，构建索引时选定，搜索时锁定)

度量方式	数学含义	实现细节	选用建议
L2 (Euclidean)	$\sqrt{\sum_i (A_i - B_i)^2}$, 空间直线距离	FAISS IndexFlatL2, Annoy euclidean	数值归一化后
Cosine	$\frac{A \cdot B}{\ A\ \ B\ }$, 方向夹角	L2 归一化 + FAISS IndexFlatIP, Annoy angular	✓ 推荐 : 不受表达量影响
Inner Product	$\sum_i A_i B_i$, 点积大小	FAISS IndexFlatIP / METRIC_INNER_PRODUCT, Annoy dot	有语义的内积场景

为什么 Cosine 是单细胞分析的默认选择?

基因表达量受测序深度影响大，余弦相似度关心**基因相对表达模式的方向相似性**，不受总量影响。L2 归一化后 $\text{Cosine} \equiv \text{Inner Product}$ ，因此在 FAISS 中实际用内积索引实现余弦检索。

后端规模

模块	数量
API 端点	25+
路由蓝图	8 个
ANN 索引类型	3 种
距离度量	3 种
数据格式支持	4 种

ANN 算法/检索库

- FAISS Flat、FAISS IVF、Annoy
- ChromaDB HNSW (联合索引)
- 三种度量 × 三种索引 = 9 种组合

前端规模

模块	数量
页面	7 个
组件	13 个
i18n 语言	中/英
图表库	Recharts
UI 框架	Material UI 5

关键功能覆盖

- 6 项课程要求全部完成
- RAG 检索 + 联合索引
- JWT 认证 + 管理员系统
- 中英文切换 + 深色/浅色主题

汇报 提纲

CONTENTS

项目背景与系统架构

核心功能实现

RAG 检索与用户权限管理

总结与后续计划

RAG 自然语言检索流程

1. 用户输入自然语言
(如“找与肝癌细胞相似的 T 细胞”)
2. Sentence-Transformers 编码语义
3. 自动提取元数据过滤条件
4. ChromaDB HNSW 语义搜索
5. AI 生成结果**统计分析与自然语言解读**




图 10: AI 智能检索

Profile 页面功能

- 查看与修改**用户名、邮箱**
- 修改密码（需验证旧密码）
- 账户信息实时更新

JWT 认证机制

- 注册：用户名 + 邮箱 + 密码
- 登录：返回 JWT access token
- 所有 API 受 @jwt_required() 保护

个人信息设置

基础信息

用户名: admin

邮箱: admin@example.com

昵称: 管理员

保存

修改密码

旧密码:

新密码:

确认新密码:

保存

图 11: 个人资料管理

管理员功能 (Admin)

- 查看所有普通用户列表
- 创建新用户、编辑用户信息
- 重置用户密码、删除用户
- 管理员账户通过 .env 自动初始化

中英文界面切换

- 完整的 i18n 翻译支持
- 导航栏一键切换语言



The image shows a registration form for 'ANN Search'. At the top right, there are links for 'EN' and a settings icon. The header includes the 'ANN Search' logo and the tagline '高维单细胞数据分析'. Below this is the title '创建账号' (Create Account). The form contains four input fields: '用户名*' (Username), '邮箱地址*' (Email address), '密码*' (Password), and '确认密码*' (Confirm Password). A blue '注册' (Register) button is positioned below the fields. At the bottom, there is a link that says '已有账号? 立即登录' (Already have an account? Log in immediately).

图 12: 登录/注册界面

汇报 提纲

CONTENTS

项目背景与系统架构

核心功能实现

RAG 检索与用户权限管理

总结与后续计划

中期已完成——六项课程要求全覆盖

- **单细胞数据读取**：支持 CSV/TSV/HDF5/H5AD，含课程 liver 数据适配
- **数据向量化表示**：PCA 嵌入 + L2 归一化 + z-score 标准化
- **ANN 索引构建**：FAISS Flat、FAISS IVF、Annoy (3 种) + ChromaDB 联合索引
- **相似细胞检索**：向量检索 / 按细胞 ID 检索 / RAG 自然语言检索
- **至少一种 ANN 算法**：实现 3 种 ANN 索引 + ChromaDB 联合索引，远超最低要求
- **Top-K + 返回细胞信息**：Top-K 可调，返回排序序号、细胞名称、距离值、全部元数据、查询耗时

附加功能

RAG AI 智能检索·多数据集联合索引·JWT 用户认证·管理员系统·距离分布可视化·CSV 导出·搜索历史管理·中英文切换

Q&A

感谢聆听，欢迎提问

软件工程第 13 组

致谢