




南开大学
Nankai University

面向单细胞数据的 ANN 检索系统

软件工程第 13 组



汇报 提纲

CONTENTS

- 01 | 项目背景与系统架构
- 02 | 核心功能实现
- 03 | RAG 检索与用户权限管理
- 04 | 总结与后续计划

项目背景

- 单细胞测序产生**数十万个细胞**样本，每个细胞是一个**高维向量**
- 传统精确搜索在大规模高维数据上**效率极低**
- ANN 技术在**质量与速度之间取得平衡**

系统目标

- 全栈 Web 应用：数据上传 → 预处理 → 索引 → 检索 → 可视化
- 至少实现一种 ANN 算法，支持





图 1: 系统整体架构图（待插入：前后端分层架构示意图）



汇报 提纲

CONTENTS

项目背景与系统架构

核心功能实现

RAG 检索与用户权限管理

总结与后续计划

支持的数据格式

- **CSV / TSV**: 通用表格格式
- **HDF5 (.h5)**: 通用层级数据格式
- **H5AD (.h5ad)**: AnnData 格式, 单细胞数据标准

课程数据适配

- 优先读取 `obsm["X_pca"]` 作为检索向量
- `obs` 元数据作为细胞标签 (`cell_type`、`disease` 等)
- 支持 UMAP / t-SNE 坐标用于可




图 3: 数据上传与管理界面 (待插入: 上传区域 + 数据集列表截图)

- 每个细胞 → 一个高维向量 (PCA 降维后 50–100 维)
- 课程数据：直接使用 `obsm["X_pca"]` 预计算 PCA 嵌入
- Demo 数据：随机生成可调维度的高斯分布向量

数据预处理

- **L2 归一化** (按细胞)：每行缩放至单位范数
- **标准化** (按特征)：每列 z-score 标准化




图 4: 数据预处理 (待插入: 预处理下拉菜单 + 预处理后状态标签截图)




图 5: 数据管理界面全貌 (待插入: Dashboard Data Management 完整截图
含上传区、数据集表格、操作按钮——Upload / Preprocess / Delete)

实现的 ANN 算法/检索库

- **FAISS Flat**: 暴力搜索, 100% 精确
- **FAISS IVF**: 倒排索引, nlist 自动计算
- **Annoy**: 随机投影树, n_trees 可调
- **ChromaDB HNSW**: 分层可导航小世界图

构建参数

- 选择数据集 + 索引类型
- 选择距离度量 (L2 / Cosine /




图 6: 索引构建界面 (待插入: 数据集选择 + 索引类型 + 度量方式 + n_trees 表单截图)




图 7: ANN 索引列表 (待插入: 已构建索引表格完整截图
含 index_type、metric、n_cells、n_features、build_time 等列)




图 8: 联合索引构建与列表 (待插入: Joint Index 构建表单 + 索引列表截图)




图 9: 联合索引跨数据集检索 (待插入: Joint Index 查询结果截图)

- 基于 ChromaDB, 支持**多数据集合并索引**与跨数据集检索
- 独立管理界面: 构建表单、索引列表、自然语言查询、结果展示

三种检索方式

- **向量检索**：直接输入数值向量
- **按细胞 ID 检索**：以数据集中某细胞为查询
- **自然语言检索**：RAG 驱动的 AI 智能搜索

检索参数

- 选择已构建的 ANN 索引
- 设置 Top-K (1-1000)
- 可选元数据过滤条件 (cell_type、disease、AgeGroup、donor_id)




图 10: 搜索面板 (待插入: 索引选择 + 向量输入/细胞 ID + k + 过滤条件截图)

Top-K 搜索结果

- 返回 **Top-K** 个最相似细胞
- 每条结果包含：**排序序号、细胞名称、距离值、全部元数据**
- 显示**查询耗时** (ms)
- 支持 **CSV 导出**与搜索历史管理

结果可视化

- Recharts **距离分布柱状图**
- 当前活跃的**过滤条件标签**
- 搜索历史：最近 10 条，支持单条/批量/全部删除




图 11: 检索结果展示 (待插入: Top-K 结果表格 + 距离分布柱状图截图)

系统支持三种距离度量，构建索引时选定，搜索时锁定。

度量方式	数学含义	实现细节	选用建议
L2 (Euclidean)	$\sqrt{\sum_i (A_i - B_i)^2}$ ，空间直线距离	FAISS IndexFlatL2, Annoy euclidean	数值归一化后
Cosine	$\frac{A \cdot B}{\ A\ \ B\ }$ ，方向夹角	L2 归一化 + FAISS IndexFlatIP, Annoy angular	✓ 推荐 ：不受表达量影响
Inner Product	$\sum_i A_i B_i$ ，点积大小	FAISS IndexFlatIP / METRIC_INNER_PRODUCT, Annoy dot	有语义的内积场景

为什么 Cosine 是单细胞分析的默认选择？

基因表达量受测序深度影响大，余弦相似度关心基因相对表达模式的方向相似性，不受测序影响。

模块	数量
API 端点	25+
前端页面/组件	7 + 13
ANN 算法/库	4 种
距离度量	3 种
数据格式	4 种

汇报 提纲

CONTENTS

项目背景与系统架构

核心功能实现

RAG 检索与用户权限管理

总结与后续计划

RAG 自然语言检索流程

1. 用户输入自然语言
(如” 找与肝癌细胞相似的 T 细胞”)
2. Sentence-Transformers 编码语义
3. 自动提取元数据过滤条件
4. ChromaDB HNSW 语义搜索
5. AI 生成结果**统计分析与自然语言解读**




图 12: AI 智能检索 (待插入: 自然语言输入 + AI 分析结果截图)

Profile 页面功能

- 查看与修改**用户名、邮箱**
- 修改密码（需验证旧密码）
- 账户信息实时更新

JWT 认证机制

- 注册：用户名 + 邮箱 + 密码
- 登录：返回 JWT access token
- 所有 API 受 @jwt_required() 保护




图 13: 个人资料管理（待插入：Profile 页面截图——修改信息 + 修改密码）

管理员功能 (Admin)

- 查看所有普通用户列表
- 创建新用户、编辑用户信息
- 重置用户密码、删除用户
- 管理员账户通过 .env 自动初始化

中英文界面切换

- 完整的 i18n 翻译支持
- 导航栏一键切换语言




图 14: 登录/注册界面 (待插入: Auth 页面截图)




图 15: 管理员用户管理 (待插入: Admin Users 页面截图)

汇报 提纲

CONTENTS

项目背景与系统架构

核心功能实现

RAG 检索与用户权限管理

总结与后续计划

中期已完成——六项课程要求全覆盖

- **单细胞数据读取**：支持 CSV/TSV/HDF5/H5AD，含课程 liver 数据适配
- **数据向量化表示**：PCA 嵌入 + L2 归一化 + z-score 标准化
- **ANN 索引构建**：FAISS Flat、FAISS IVF、Annoy、ChromaDB HNSW（4 种）
- **相似细胞检索**：向量检索 / 按细胞 ID 检索 / RAG 自然语言检索
- **至少一种 ANN 算法**：实现 4 种 ANN 算法/检索库，远超最低要求
- **Top-K + 返回细胞信息**：Top-K 可调，返回排序序号、细胞名称、距离值、全部元数据、查询耗时

附加功能

RAG AI 智能检索·多数据集联合索引·JWT 用户认证·管理员系统·距离分布可视化·CSV 导出·搜索历史管理·中英文切换

Q&A

感谢聆听，欢迎提问

软件工程第 13 组

致谢