




南开大学
Nankai University

面向单细胞数据的 ANN 检索系统

软件工程第 13 组



汇报 提纲

CONTENTS

01 | 项目背景与系统架构

02 | 核心功能实现

03 | RAG 检索与用户权限管理

04 | 总结与后续计划

项目背景

- 单细胞测序产生**数十万个细胞**样本，每个细胞是一个**高维向量**
- 传统精确搜索在大规模高维数据上**效率极低**
- ANN 技术在**质量与速度之间取得平衡**

系统目标

- 全栈 Web 应用：数据上传 → 预处理 → 索引 → 检索 → 可视化
- 至少实现一种 ANN 算法，支持





图 1: 系统整体架构图（待插入：前后端分层架构示意图）



汇报 提纲

CONTENTS

项目背景与系统架构

核心功能实现

RAG 检索与用户权限管理

总结与后续计划

支持的数据格式

- CSV / TSV / HDF5 / H5AD
(AnnData)

课程数据适配

- 优先读取 `obsm["X_pca"]` 作为检索向量
- `obs` 元数据作为细胞标签和过滤字段

数据预处理

- L2 归一化 (按细胞)
- 按特征 z-score 标准化




图 3: 数据上传与管理界面 (待插入: 数据上传 + 数据集列表截图)




图 4: 数据预处理 (待插入: 预处理操作 + 预处理状态截图)

实现的 ANN 算法/检索库 (4 种)

- **FAISS Flat**: 暴力搜索, 精确结果
- **FAISS IVF**: 倒排索引加速
- **Annoy**: 随机投影树
- **ChromaDB HNSW**: 联合索引

构建参数

- 索引类型可选
- 距离度量可选 (L2 / Cosine / IP)




图 5: 索引构建表单 (待插入: 构建参数选择界面截图)




图 6: 索引列表 (待插入: 已构建索引列表截图, 展示 4 种算法条目)

三种检索方式

- **向量检索**: 直接输入数值向量
- **按细胞 ID 检索**: 以数据集中的某细胞为查询
- **自然语言检索**: RAG 驱动的 AI 搜索

检索参数与返回信息

- **Top-K**: 1-1000 可调
- **距离度量**: L2 / Cosine / Inner Product
- **元数据过滤**: cell_type、disease、AgeGroup、donor_id
- **返回**: 细胞名称、排序序号、距离值、




图 7: 搜索面板 (待插入: 检索参数输入界面完整截图)




图 8: 检索结果展示 (待插入: Top-K 结果表格 + 距离分布图截图)




图 9: 数据管理界面




图 10: 索引管理界面




图 11: 搜索与结果界面




图 12: AI 智能检索界面




图 13: 联合索引管理界面




图 14: 个人资料管理界面

系统支持三种距离度量，构建索引时选定，搜索时锁定。

度量方式	数学含义	实现细节	选用建议
L2 (Euclidean)	$\sqrt{\sum_i (A_i - B_i)^2}$ ，空间直线距离	FAISS IndexFlatL2, Annoy euclidean	数值归一化后
Cosine	$\frac{A \cdot B}{\ A\ \ B\ }$ ，方向夹角	L2 归一化 + FAISS IndexFlatIP, Annoy angular	✓ 推荐 ：不受表达量影响
Inner Product	$\sum_i A_i B_i$ ，点积大小	FAISS IndexFlatIP / METRIC_INNER_PRODUCT, Annoy dot	有语义的内积场景

为什么 Cosine 是单细胞分析的默认选择？

基因表达量受测序深度影响大，余弦相似度关心基因相对表达模式的方向相似性，不受测序影响。

模块	数量
API 端点	25+
前端页面/组件	7 + 13
ANN 算法/库	4 种
距离度量	3 种
数据格式	4 种

汇报 提纲

CONTENTS

项目背景与系统架构

核心功能实现

RAG 检索与用户权限管理

总结与后续计划

RAG 智能检索流程

1. 用户输入自然语言（如“找与肝癌细胞相似的 T 细胞”）
2. Sentence-Transformers 编码查询语义
3. 自动提取元数据过滤条件（cell_type、disease 等）
4. ChromaDB HNSW 语义相似搜索
5. AI 对 Top-K 结果统计分析并生成自然语言解读

联合索引 (Joint Index)





图 15: RAG 自然语言检索（待插入：AI 搜索输入 + 结果 + 分析截图）



用户认证 (JWT)

- 注册 + 登录, 返回 JWT access token
- 所有 API 受 @jwt_required() 保护

个人账户 (Profile)

- 修改用户名、邮箱 (需验证唯一性)
- 修改密码 (需验证旧密码)

管理员功能 (Admin)

- 查看所有普通用户列表
- 创建 / 编辑 / 删除用户、重置密码
- 管理员账户通过 .env 自动初始化




图 17: 登录/注册界面 (待插入: Auth 页面截图)




图 18: 管理员用户管理 (待插入: Admin Users 页面截图)

汇报 提纲

CONTENTS

项目背景与系统架构

核心功能实现

RAG 检索与用户权限管理

总结与后续计划

中期已完成的核心工作

- **完整功能闭环**：数据上传 → 预处理 → ANN 索引构建 → 相似检索 → 结果可视化
- **ANN 算法覆盖**：实现 4 种 ANN 算法/检索库 (FAISS Flat、FAISS IVF、Annoy、ChromaDB HNSW)
- **Top-K 检索**：支持向量检索/按细胞 ID 检索/RAG 自然语言检索，返回完整细胞信息与元数据
- **全部课程要求覆盖**：单细胞数据读取、向量化表示、ANN 索引构建、相似细胞检索、 ≥ 1 种 ANN 算法、Top-K+ 返回细胞信息
- **距离度量**：支持 L2 / Cosine / Inner Product 三种度量，Cosine 为单细胞分析的推荐默认值
- **附加功能**：用户认证 (JWT)、管理员系统、RAG 检索、联合索引、由英文切

Q&A

感谢聆听，欢迎提问

软件工程第 13 组

致谢